

# Dyskretyzacja, PCA, MDS

## Eksploracja danych - Lista nr 2

Ksawery Józefowski, 277513

2025-04-30

### Spis treści

<b>1 Zadanie nr 1</b>	<b>2</b>
1.1 Wprowadzenie . . . . .	2
1.2 Statystyki Opisowe . . . . .	2
1.3 Wybór Cech . . . . .	4
1.4 Implementacja metod . . . . .	4
1.5 Ocena skuteczności . . . . .	7
<b>2 Zadanie nr 2</b>	<b>8</b>
2.1 Wprowadzenie . . . . .	8
2.2 Analiza wariacji zmiennych . . . . .	8
2.3 Składowe Główne . . . . .	9
2.4 Wizualizacja danych wielowymiarowych . . . . .	12
2.5 Korelacja zmiennych . . . . .	14
2.6 Wnioski . . . . .	16
<b>3 Zadanie nr 3</b>	<b>16</b>
3.1 Wprowadzenie . . . . .	16
3.2 Przygotowanie danych . . . . .	16
3.3 Redukcja wymiaru . . . . .	17
3.4 Wizualizacja . . . . .	18

# 1 Zadanie nr 1

## 1.1 Wprowadzenie

Przeprowadzamy analizę procesu *dyskretyzacji* cech ciągłych w zbiorze danych `iris`. Celem jest porównanie skuteczności różnych metod nienadzorowanej dyskretyzacji:

1. Equal Width
2. Equal Frequency
3. K-means clustering

## 1.2 Statystyki Opisowe

Tabela 1: Statystyki opisowe zbioru Iris


Sepal.Length	Sepal.Width	Petal.Length	Petal.Width	Species
Min. :4.300	Min. :2.000	Min. :1.000	Min. :0.100	setosa :50
1st Qu.:5.100	1st Qu.:2.800	1st Qu.:1.600	1st Qu.:0.300	versicolor:50
Median :5.800	Median :3.000	Median :4.350	Median :1.300	virginica :50
Mean :5.843	Mean :3.057	Mean :3.758	Mean :1.199	NA
3rd Qu.:6.400	3rd Qu.:3.300	3rd Qu.:5.100	3rd Qu.:1.800	NA
Max. :7.900	Max. :4.400	Max. :6.900	Max. :2.500	NA

Z Tabla 1 wynika, że średnie wartości dla:

- Sepal to Width - 3.06 i Length - 5.84
- Petal to Width - 1.20 i Length - 3.76

Można z tego wywnioskować, że wymiary Petal wykazują większą zmienność.

Przejdźmy teraz do rozkładów zmiennych.



Rysunek 1: Rozkłady cech

Z 1 obserwujemy, że wymiary dla Petal prawie wcale nie pokrywają się gatunkowo.


### 1.3 Wybór Cech

Na podstawie analizy statystyk opisowych możemy wybrać cechy dyskryminujące:


- Najlepsza cecha dyskryminująca to Petal.Length
- Najgorsza cecha dyskryminująca to Sepal.Width

### 1.4 Implementacja metod

Wybrane przez nas cechy dyskretyzujemy za pomocą funkcji `discretize` na 4 różne metody. Zwizualizujemy je za pomocą wykresów rozrzutu.



Rysunek 2: Porównanie metod



Rysunek 3: Porównanie metod

## 1.5 Ocena skuteczności

Tabela 2: Skuteczność dyskretyzacji różnych metod

Method	Feature	Accuracy
Equal Width	Petal.Length	0.95
Equal Frequency	Petal.Length	0.95
K-means	Petal.Length	0.95
Fixed	Petal.Length	0.95
Equal Width	Sepal.Width	0.17
Equal Frequency	Sepal.Width	0.21
K-means	Sepal.Width	0.27
Fixed	Sepal.Width	0.33


Z Tabela 2 wnioskujemy, że najbardziej dokładną metodą dyskretyzacji była Equal Frequency dla Petal.Length. Wyniki dla wybranej Najlepszej i Najgorszej cechy różnią się istotnie i wskazują, że Sepal.Width słabo odzwierciedla podział na klasy.

## 2 Zadanie nr 2

### 2.1 Wprowadzenie

W tym zadaniu zastosujemy PCA do zbioru danych dotyczących jakości życia w różnych miastach świata. Celem analizy było zidentyfikowanie głównych czynników różnicujących miasta oraz redukcja wymiarowości danych.

### 2.2 Analiza wariacji zmiennych





Rysunek 4: Przed i po standaryzacji

Na podstawie wykresu pudełkowego widać, że zmienne mają różne wariancje przed standaryzacją. Po standaryzacji wszystkie zmienne mają podobny rozrzut, co jest pożądane w analizie PCA.

## 2.3 Składowe Główne

Rozrzut wartości dla pierwszych trzech składowych



Rysunek 5: Wykresy głównych składowych

Tabela 3: Ładunki (Loadings) dla PC1, PC2, PC3

	PC1	PC2	PC3
Housing	0.308	0.053	-0.314
Cost of Living	0.260	-0.176	-0.331
Startups	-0.180	-0.483	0.006
Venture Capital	-0.237	-0.427	0.015
Travel Connectivity	-0.209	-0.135	-0.340
Commute	-0.114	0.026	-0.506
Business Freedom	-0.377	0.098	0.024
Safety	-0.039	0.287	-0.333
Healthcare	-0.280	0.242	-0.281
Education	-0.403	-0.049	-0.074
Environmental Quality	-0.326	0.253	0.054
Economy	-0.273	-0.074	0.309
Taxation	0.026	0.107	-0.020
Internet Access	-0.276	0.023	0.028
Leisure & Culture	-0.074	-0.365	-0.305
Tolerance	-0.190	0.355	-0.103
Outdoors	-0.092	-0.193	-0.149

Analizując wyniki otrzymane możemy wywnioskować, że pierwsze 3 główne składowe wyjaśniają odpowiednio 30%, 15% i 12% wariancji danych, co łącznie daje nam 57% wyjaśnionej wariancji. Rozkład wartości składowych pokazuje, że PC1 ma najszerzy rozrzut (od -2.5 do 5.0), co potwierdza jej dominujący udział w wyjaśnianiu zmienności danych. Kolejne składowe mają coraz mniejszy rozrzut wartości.

### 2.3.1 Interpretacja PC1

Ta składowa wyraźnie przeciwstawia dobre warunki mieszkaniowe i niższe koszty utrzymania (wartości dodatnie) wysokiej jakości edukacji i swobodzie biznesowej (wartości ujemne). Można ją interpretować jako wymiar “przystępności życiowej”.


### 2.3.2 Interpretacja PC2

Ta składowa pokazuje napięcie między otwartością społeczną i bezpieczeństwem a dynamicznym środowiskiem biznesowym i kulturalnym. Ukazuje ona Społeczno-kulturalny vs. biznesowy charakter miasta

### 2.3.3 Interpretacja PC3

Wymiar ten łączy kwestie mobilności (dojazdy, łączność podróżniczą) z czynnikami ekonomicznymi, pokazując kompromis między dostępnością transportu a warunkami mieszkaniowymi.

#### 2.3.4 Liczba składowych potrzebnych do wyjaśnienia wariancji



Rysunek 6: Wykres wariancji

Z wykresu możemy wyczytać, że aby wyjaśnić:

- 80% wariancji potrzebujemy 7 składowych głównych
- 90% wariancji potrzebujemy 10 składowych głównych

## 2.4 Wizualizacja danych wielowymiarowych




Tabela 4: Najbardziej charakterystyczne miasta w analizie PCA

Miasto	Kraj	Kontynent	PC1	PC2	PC3
Andorra	Andorra	Europe	3.897114	2.3137642	3.4991109
Belize City	Belize	North America	3.404133	2.1271014	4.0724131
London	United Kingdom	Europe	-4.407120	-3.4161324	-1.1871912
New York	New York	North America	-4.152618	-3.8075415	-0.0073126
Lagos	Nigeria	Africa	4.793546	-2.0852009	1.8912837
Dar es Salaam	Tanzania	Africa	4.748133	-1.0837930	2.4961800
San Francisco Bay Area	California	North America	-4.040812	-3.4337912	0.7839549
Caracas	Venezuela	South America	5.136607	-0.8705013	0.5117261
Los Angeles	California	North America	-3.202975	-4.0030138	0.8891155
Managua	Nicaragua	North America	2.743539	2.7322205	3.3934242

Na podstawie wykresów obserwujemy wyraźne skupiska miast o podobnych charakterystykach. Miasta z tego samego regionu geograficznego wykazują znaczące podobieństwo w przestrzeni składowych głównych, co sugeruje wspólne wzorce w: Strukturze kosztów życia, Jakości usług publicznych, Rozwoju infrastruktury, Środowisku biznesowym.

Wyłania się wyraźny obraz naturalnego grupowania miast według kryteriów geograficznych i społeczno-ekonomicznych. Przestrzeń wyznaczona przez pierwsze dwie składowe główne (PC1 i PC2) odsłania fascynujące prawidłowości w rozmieszczeniu ośrodków miejskich, przy czym aż 45% całkowitej zmienności danych tłumaczą właśnie te dwa wymiary.

*Naturalne skupiska* miejskie układają się w charakterystyczne konstelacje:

- *Europejski archipelag* skupia się w prawym górnym kwadrancie, z Andorą jako jasną gwiazdą ( $PC1=3.90$ ,  $PC2=2.31$ ), odzwierciedlającą model zrównoważonego rozwoju alpejskiego. Miasta te łączy korzystny bilans między standardem życia a kosztami utrzymania.
- *Amerykańskie megapolis* jak Nowy Jork ( $PC1=-4.15$ ) i Los Angeles ( $PC1=-3.20$ ) tworzą zwartą grupę w lewym dolnym rogu, ucieleśniając model metropolii globalnych z wysokimi kosztami, ale i znakomitą infrastrukturą.
- *Afrykańskie perły* takie jak Lagos ( $PC1=4.79$ ) i Dar es Salaam ( $PC1=4.75$ ) sytuują się w prawym dolnym kwadrancie, prezentując unikalny kompromis między przystępnością cenową a dynamicznym rozwojem.


*Miasta-outsiderzy* przyciągają uwagę swoim nietypowym położeniem w przestrzeni PCA:

- *Caracas* - wenezuelska anomalia ( $PC1=5.14$ ) świeci najjaśniejszym światłem w rankingu warunków mieszkaniowych, stanowiąc ekonomiczny fenomen w regionie. Jej pozycja sugeruje nieoczekiwane korzystny stosunek jakości do ceny nieruchomości, co może wynikać ze specyficznej sytuacji gospodarczej kraju.
- *San Francisco Bay Area* - technologiczny tygrys ( $PC2=-3.43$ ) prezentuje skrajny model rozwoju, gdzie niewyobrażalne koszty życia ( $PC1=-4.04$ ) idą w parze z wyjątkowymi możliwościami biznesowymi (dodatnie  $PC3=0.78$ ). To miasto przyszłości, które zapłaciło wysoką cenę za swoją innowacyjność.
- *Managua* - nikaraguańska niespodzianka ( $PC2=2.73$ ) błyszczy nieoczekiwanymi wynikami w zakresie usług publicznych, przewyższając wiele bogatszych sąsiadów. Jej pozycja wskazuje na efektywny model zarządzania miejskiego w trudnych warunkach ekonomicznych.

*Fenomen grupowania* ujawnia głębsze prawidłowości:


- Kontynenty układają się w charakterystyczne sekwencje wzduż osi PC1, od Afryki przez Europę po Amerykę Północną, co odzwierciedla gradient rozwojowy.
- W obrębie każdego regionu widoczne są lokalne wzorce - np. europejskie miasta alpejskie (Andorra) versus metropole zachodnie (Londyn).
- Pozycja miast w przestrzeni PCA koreluje z ich historycznym modelem rozwoju i obecną strategią gospodarczą.

## 2.5 Korelacja zmiennych



Rysunek 7: Korelacje biplot

## Macierz korelacji



Rysunek 8: Macierz Korelacji

Patrząc na biplot, można zauważyc, że zmienne takie jak **Startups**, **Venture Capital**, **Business Freedom** oraz częściowo **Internet Access** są skierowane w podobnym kierunku, co sugeruje silną dodatnią korelację pomiędzy nimi. Również zmienne **Housing** i **Cost of Living** są blisko siebie, co wskazuje na dodatnią zależność. Widać też, że **Environmental Quality** jest skierowane w stronę przeciwną do **Housing** i **Cost of Living**, co sugeruje ujemną korelację między nimi. Ponadto zmienne takie jak **Tolerance**, **Safety** oraz **Environmental Quality** tworzą zgrupowanie, co może świadczyć o ich dodatniej korelacji.

Analizując wyniki macierzy korelacji, można potwierdzić intuicje wyciągnięte z biplotu. Widzimy, że zmienne **Startups** i **Venture Capital** mają bardzo wysoką dodatnią korelację o wartości 0,8. Podobnie zmienne **Cost of Living** i **Housing** cechują się umiarkowaną dodatnią korelacją na poziomie 0,57. W przypadku **Environmental Quality** obserwuje się ujemną korelację zarówno z **Cost of Living** (-0,25), jak i z **Housing** (-0,43). Dodatkowo zmienne **Tolerance** i **Safety** są dodatnio skorelowane ze sobą, osiągając współczynnik korelacji równy 0,43.

Podsumowując, zarówno analiza biplotu PCA, jak i macierzy korelacji prowadzą do spójnych wniosków dotyczących zależności między zmiennymi. Biplot dostarcza graficznej, intuicyjnej interpretacji zależności, natomiast macierz korelacji pozwala je dokładnie zweryfikować za pomocą wartości liczbowych.

## 2.6 Wnioski

W przeprowadzonej analizie PCA udało się zaobserwować kilka ciekawych zależności. Przede wszystkim pierwsze trzy składowe główne (PC1, PC2, PC3) wyjaśniają łącznie 57% całkowitej wariancji w danych, z czego PC1 odpowiada za 29,8%, PC2 za 15,2%, a PC3 za 12,2%. W przestrzeni pierwszych dwóch składowych (PC1 i PC2) uwidocznili się wyraźne skupiska miast, odpowiadające ich położeniu geograficznemu oraz charakterystyce społeczno-ekonomicznej. Przykładowo, miasta europejskie, amerykańskie oraz afrykańskie tworzyły odrębne grupy, natomiast miasta takie jak Caracas, San Francisco Bay Area czy Managua wyróżniały się nietypowym położeniem w przestrzeni głównych składowych, co odzwierciedlało ich specyficzne warunki gospodarcze i społeczne. Ponadto analiza biplotu oraz macierzy korelacji potwierdziła istnienie silnych zależności między niektórymi zmiennymi, m.in. wysoką dodatnią korelację między **Startups** a **Venture Capital** (około 0,8) oraz umiarkowaną dodatnią korelację między **Cost of Living** a **Housing** (około 0,57).

Aby uzyskać zadowalającą reprezentację danych, obejmującą około 80% całkowitej wariancji, konieczne było uwzględnienie 7 głównych składowych. Wyjaśnienie 90% wariancji wymagało już 10 składowych, co pokazuje, że struktura danych jest stosunkowo złożona i wymaga większej liczby wymiarów do pełnego uchwycenia różnorodności informacji.

Istotny wpływ na otrzymane wyniki miało zastosowanie standaryzacji zmiennych. Przed standaryzacją zmienne cechowały się znacznymi różnicami w wariancji, co mogłoby prowadzić do dominacji zmiennych o największej zmienności w analizie PCA. Dzięki standaryzacji wszystkie zmienne uzyskały porównywalny rozrzut, co umożliwiło przeprowadzenie rzetelnej analizy i wyciągnięcie wiarygodnych wniosków. Bez przeprowadzenia standaryzacji wyniki PCA byłyby znacznie mniej miarodajne.

## 3 Zadanie nr 3


### 3.1 Wprowadzenie

Przeprowadzimy analizę zbioru danych `titanic_train` z pakietu `titanic` przy użyciu skalowania wielowymiarowego. Celem analizy jest redukcja wymiaru danych i ocena widocznych struktur (grup) wśród pasażerów Titanica na podstawie wybranych zmiennych.

### 3.2 Przygotowanie danych

Na początku wczytano zbiór `titanic_train` z pakietu `titanic` w R i przekonwertowano zmienne kategoryczne (`Survived`, `Pclass`, `Sex`, `Embarked`) na typ `factor`, aby zapewnić ich poprawne traktowanie podczas analizy. Usunięto także zmienne pełniące rolę identyfikatorów (`PassengerId`, `Name`, `Ticket`, `Cabin`), ponieważ nie wnoszą one istotnych informacji do skalowania wielowymiarowego. Dodatkowo zmienną `Survived` wyłączono z dalszej analizy wymiarowej, pozostawiając ją jedynie do późniejszej interpretacji wyników.


### 3.3 Redukcja wymiaru



Rysunek 9: Wykres Sheparda

Aby ocenić jakość otrzymanego odwzorowania, wykorzystano diagram Sheparda. Diagram ten przedstawia zależność między oryginalnymi odmiennościami (z macierzy odmienności) a odległościami w przestrzeni docelowej. Punkty na diagramie układają się blisko linii  $y = x$ , oznacza to, że odwzorowanie dobrze zachowuje oryginalne odległości między obserwacjami przy małych wartościach. Odstępstwa od idealnej linii implikują, że przy większych wartościach pojawi się większy rozrzut. Odmienności w odwzorowaniu powinny być jak najmniejsze, w naszym przypadku odmienności świadczą umiarkowanie dobrej jakości redukcji wymiaru.

### 3.4 Wizualizacja



Rysunek 10: Wizualizacja po redukcji

### **3.4.1 Interpretacja wyników**

#### **3.4.1.1 Podział według przeżycia (Survived):**

Na wykresie widoczny jest częściowy podział na dwie grupy:

- Nie Przeżyli: Skupiają się głównie w obszarze dodatnich wartości Dim1 (~0.2 do 0.4) i umiarkowanych Dim2
- Przeżyli: Dominują w zakresie ujemnych wartości Dim1 (-0.4 do 0)

Podział jest umiarkowanie zgodny z rzeczywistymi wynikami przeżycia (~65% zgodności). Widoczne nakładanie się grup sugeruje, że czynniki inne niż te uwzględnione w modelu wpływają na przeżycie i istniały wyjątki od ogólnych wzorców (np. kobiety które nie przeżyły).

#### **3.4.1.2 Obserwacje odstające:**

Kilka niebieskich punktów (przeżyli) w lewym górnym rogu Pojedyńczy czerwony punkt (nie przeżyli) w prawym dolnym rogu Dolna część wykresu, okolice ( $\text{Dim1} = -0.2$ ,  $\text{Dim2} = -0.3$ ): pojedyncze czerwone punkty (Survived == 0) również odstają od reszty.

#### **3.4.1.3 Podział według płci:**

Kobiet wyraźnie skupione po lewej stronie ( $\text{Dim1} < 0$ ) Mężczyźni za to zgrupowani po lewej stronie ( $\text{Dim1} > 0$ )

Rozmieszczenie niemal idealnie pokrywa się z podziałem na przeżycie, potwierdzając zasadę “kobiety i dzieci pierwsze”.

#### **3.4.1.4 Podział według klasy:**

1 klasa jest skupiona w prawym górnym kwadrancie

2 klasa jest w środkowy obszar wykresu

3 klasa znajduje się w lewej dolnej części wykresu

Układ klas pokrywa się z wykresem zmiennej `survived` i `sex`. Ciekawą obserwacją jest to, że część najbiedniejszych kobiet nie przeżyła co może świadczyć o tym, że pierwszeństwo na szalupy miały bogatsze kobiety.